

Федеральное государственное образовательное
учреждение
высшего образования
«Московский государственный технический университет имени
Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

Факультет ИУ - «Информатика и управление»

Кафедра ИУ5 - «Системы обработки информации и управления»

Лабораторная работа №1 по курсу «Технологии машинного
обучения»
на тему «Разведочный анализ данных. Исследование и
визуализация данных.»

Студент группы ИУ3С-52Б: Хайдаров Роман Русланович
Преподаватель кафедры ИУ5: Ованнес Гагикович Саргсян

1. Цель работы

Провести первичный исследовательский анализ табличного набора данных: изучить структуру и типы признаков, определить наличие пропущенных значений, рассчитать основные статистические характеристики и выполнить визуальный анализ распределений и взаимосвязей между числовыми признаками.

2. Используемые средства

В работе используется Python 3. Для загрузки и обработки данных применяются библиотеки NumPy и Pandas, для визуализации - Seaborn и Matplotlib. В notebook включен режим отображения графиков непосредственно в Jupyter.

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
```

3. Исходные данные

Исходный набор загружается из файла mcu.csv с помощью функции pandas.read_csv. Согласно результату data.shape, набор содержит 62 строки и 10 столбцов.

```
data = pd.read_csv('mcu.csv', sep=',')
data.shape # (62, 10)
```

Таблица 1 - Структура набора данных

Признак	Тип	Содержание
movie_title	object	Название фильма
mcu_phase	object	Фаза MCU
release_date	object	Дата выхода
tomato_meter	int64	Числовой рейтинг tomato_meter
audience_score	int64	Оценка аудитории
movie_duration	float64	Продолжительность фильма
production_budget	float64	Бюджет производства
opening_weekend	float64	Сборы за первый уикенд

Признак	Тип	Содержание
domestic_box_office	float64	Внутренние кассовые сборы
worldwide_box_office	float64	Мировые кассовые сборы

Первые пять записей относятся к фильмам Iron Man, The Incredible Hulk, Iron Man 2, Thor и Captain America The First Avenger. Для каждого объекта представлены рейтинги, продолжительность и кассовые показатели.

4. Первичный анализ данных

4.1. Проверка пропущенных значений

Для каждого столбца подсчитывается число пустых значений. Полностью заполнены строковые признаки, дата выхода и два рейтинговых признака. В пяти числовых столбцах обнаружено по 24 пропуска.

```
for col in data.columns:
    temp_null_count = data[data[col].isnull()].shape[0]
    print('{} - {}'.format(col, temp_null_count))
```

Таблица 3 - Количество пропусков

Признак	Пропуски
movie_duration	24
production_budget	24
opening_weekend	24
domestic_box_office	24
worldwide_box_office	24

Ключевое наблюдение. Во всех остальных столбцах пропусков нет. Для перечисленных пяти числовых признаков доступно по 38 непустых наблюдений, что соответствует статистике count в data.describe().

4.2. Описательная статистика

Команда data.describe() показывает основные характеристики числовых признаков. Для компактности денежные показатели в таблице ниже приведены в миллионах единиц исходного датасета.

Таблица 4 - Основные статистические характеристики

Признак	count	mean	median	min	max
tomato_meter	62	82,63	86,00	46,00	99,00
audience_score	62	81,21	86,00	32,00	98,00
movie_duration	38	130,87	128,50	105,00	181,00
production_budget, млн	38	203,46	200,00	130,00	365,00
opening_weekend, млн	38	137,73	117,34	46,11	360,09
domestic_box_office, млн	38	367,13	326,11	84,50	858,40
worldwide_box_office, млн	38	913,76	767,14	206,14	2 799,44

Показатель tomato_meter имеет среднее значение 82,63 и медиану 86, что указывает на преобладание высоких оценок. Минимальное значение равно 46, максимальное - 99. Для audience_score среднее составляет 81,21, медиана - 86.

5. Визуальный анализ

5.1. Связь сборов первого уикенда и мировых сборов

Диаграмма рассеяния построена для признаков opening_weekend и worldwide_box_office. Точки формируют выраженный восходящий тренд: фильмы с более высокими сборами в первый уикенд, как правило, имеют более высокие итоговые мировые сборы.

```
fig, ax = plt.subplots(figsize=(10,10))
sns.scatterplot(ax=ax, x='opening_weekend',
                y='worldwide_box_office', data=data)
```




Рисунок 1 - Диаграмма рассеяния *opening_weekend* и *worldwide_box_office*

На графике также заметны отдельные фильмы с особенно крупными кассовыми значениями. При этом общая направленность зависимости сохраняется на всем диапазоне доступных наблюдений.

5.2. Распределение *tomato_meter*

Для рейтинга *tomato_meter* построены гистограмма с оценкой плотности и *boxplot*. Основная часть наблюдений сосредоточена в области высоких значений - примерно от 75 до 100, а в левой части распределения присутствует небольшой хвост. *Boxplot* подтверждает наличие нескольких низких значений, удаленных от основной группы.




Рисунок 2 - Распределение *tomato_meter*




Рисунок 3 - Boxplot для *tomato_meter*

Медиана *tomato_meter* равна 86, а межквартильный диапазон по `data.describe()` составляет от 77 до 91,75. Низкие значения на boxplot визуально соответствуют отдельным наблюдениям в нижней части диапазона.

5.3. Парные зависимости числовых признаков

Функция `sns.pairplot(data)` строит матрицу попарных диаграмм рассеяния и одномерных распределений. В notebook вызов `pairplot` выполнен дважды; в отчет включен один экземпляр, поскольку результаты идентичны.




Рисунок 4 - Матрица парных диаграмм числовых признаков

Матрица показывает наиболее выраженную совместную изменчивость между коммерческими показателями: `opening_weekend`, `domestic_box_office` и `worldwide_box_office`. Для рейтинговых признаков зависимости с кассовыми показателями визуально слабее и имеют больший разброс.

5.4. Корреляционная матрица

Для семи числовых признаков рассчитана корреляционная матрица и построена тепловая карта. Цветовая шкала позволяет сравнить направление и относительную силу линейных связей.

```
sns.heatmap(data[['tomato_meter', 'audience_score', 'movie_duration',  
                  'production_budget', 'opening_weekend',  
                  'domestic_box_office', 'worldwide_box_office']].corr())
```




Рисунок 5 - Тепловая карта корреляций числовых признаков

Наиболее сильные положительные связи визуально наблюдаются внутри группы кассовых показателей, особенно между внутренними и мировыми сборами, а также между сборами первого уикенда и итоговыми сборами. Связь рейтингов с финансовыми признаками заметно слабее.

6. Основные результаты

- Размер набора данных - 62 объекта и 10 признаков.
- Признаки `movie_title`, `mcu_phase`, `release_date`, `tomato_meter` и `audience_score` не содержат пропусков.
- В `movie_duration`, `production_budget`, `opening_weekend`, `domestic_box_office` и `worldwide_box_office` содержится по 24 пропуска; для этих признаков доступно 38 наблюдений.
- Рейтинг `tomato_meter` в целом высокий: среднее 82,63, медиана 86, минимум 46, максимум 99.
- Распределение `tomato_meter` смещено в сторону высоких оценок; `boxplot` выделяет несколько сравнительно низких значений.
- Диаграмма рассеяния и корреляционная тепловая карта показывают сильную положительную связь между показателями кассовых сборов.
- Парные графики подтверждают, что коммерческие признаки связаны между собой заметно сильнее, чем с рейтинговыми показателями.

7. Вывод

В ходе лабораторной работы выполнен полный базовый цикл разведочного анализа данных: загрузка набора, изучение его структуры, проверка типов и пропусков, расчет описательной статистики и построение основных видов визуализаций. Анализ показал, что набор содержит преимущественно высокие значения `tomato_meter`, но также включает несколько низких наблюдений. Финансовые показатели фильмов демонстрируют выраженную положительную взаимосвязь, особенно для сборов первого уикенда, внутренних и мировых кассовых сборов. Существенной особенностью исходных данных является наличие 24 пропусков в пяти числовых признаках, что необходимо учитывать при дальнейшем моделировании и статистическом анализе.