Федеральное государственное образовательное
учреждение
высшего образования
«Московский государственный технический университет имени
Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

Факультет ИУ - «Информатика и управление»

Кафедра ИУ5 - «Системы обработки информации и управления»

Лабораторная работа №2 по курсу «Технологии машинного обучения»
на тему «Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных»

Студент группы ИУ3С-52Б: Хайдаров Роман Русланович
Преподаватель кафедры ИУ5: Ованнес Гагикович Саргсян

1. Цель работы

Изучить способы предварительной обработки табличных данных для последующего построения моделей машинного обучения: провести анализ пропущенных значений, выбрать способ их обработки, выполнить кодирование категориальных признаков и сравнить методы масштабирования числовых показателей.

2. Используемые средства

В работе используется Python 3. Для загрузки и обработки данных применяются библиотеки Pandas и NumPy, для построения графиков - Matplotlib. Для заполнения пропусков и преобразования признаков использованы классы SimpleImputer, OneHotEncoder, MinMaxScaler и StandardScaler из scikit-learn.

```
from pathlib import Path
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import OneHotEncoder, MinMaxScaler, StandardScaler
```

3. Исходные данные

Для исследования выбран файл dataset.csv, содержащий социальные и экономические показатели стран за период с 2000 по 2025 год. После загрузки через pandas.read_csv() в наборе обнаружено 5 642 строки и 19 столбцов. Данные охватывают 217 различных кодов стран.

```
data = pd.read_csv('dataset.csv')
data.shape  # (5642, 19)
```

Таблица 1 - Структура исходного набора данных

Признак	Тип	Содержание
country_code	object	Трёхбуквенный код страны
country_name	object	Наименование страны
year	int64	Год статистического наблюдения
gdp_usd	float64	Валовой внутренний продукт, долл. США

Признак	Тип	Содержание
gdp_growth_pct	float64	Темп роста ВВП, %
gdp_per_capita_usd	float64	ВВП на душу населения, долл. США
inflation_cpi_pct	float64	Инфляция по индексу потребительских цен, %
real_interest_rate_pct	float64	Реальная процентная ставка, %
unemployment_rate_pct	float64	Уровень безработицы, %
labor_force_total	float64	Численность рабочей силы
population_total	float64	Численность населения
life_expectancy	float64	Ожидаемая продолжительность жизни
trade_pct_gdp	float64	Внешнеторговый оборот, % ВВП
exports_pct_gdp	float64	Экспорт, % ВВП
imports_pct_gdp	float64	Импорт, % ВВП
current_account_pct_gdp	float64	Счёт текущих операций, % ВВП
fdi_inflows_pct_gdp	float64	Приток прямых иностранных инвестиций, % ВВП
internet_users_pct	float64	Доля пользователей Интернета, %
electricity_access_pct	float64	Доступ к электроэнергии, % населения

Признаки country_code и country_name являются строковыми, year содержит целочисленные значения; остальные 16 показателей имеют тип float64. В первых строках набора представлены статистические данные об Арубе (ABW) за 2000-2004 годы.

4. Первичный анализ данных

4.1. Проверка пропущенных значений

Для каждого столбца определены количество пропусков и их доля от общего числа наблюдений. Пропущенные значения обнаружены в 15 столбцах из 19. Хотя бы одно отсутствующее значение содержится в 3 354 строках, что составляет 59,45% выборки.

```
missing = data.isna().sum()
missing = missing[missing > 0].sort_values(ascending=False)
missing_pct = (missing / len(data) * 100).round(2)
print(data.isna().any(axis=1).sum())  # 3354
```

Таблица 2 - Количество пропусков по числовым признакам

Признак	Пропуски	Доля, %
real_interest_rate_pct	2 508	44,45
current_account_pct_gdp	1 130	20,03
trade_pct_gdp	1 054	18,68
exports_pct_gdp	1 054	18,68
imports_pct_gdp	1 054	18,68
inflation_cpi_pct	958	16,98
unemployment_rate_pct	794	14,07
labor_force_total	794	14,07
internet_users_pct	742	13,15
fdi_inflows_pct_gdp	726	12,87
electricity_access_pct	292	5,18
gdp_growth_pct	288	5,10
life_expectancy	217	3,85
gdp_usd	214	3,79
gdp_per_capita_usd	214	3,79

В признаке real_interest_rate_pct отсутствует 2 508 значений (44,45%); сравнительно много пропусков также в current_account_pct_gdp (20,03%) и трёх показателях внешней торговли (по 18,68%). Столбцы country_code, country_name, year и population_total заполнены полностью.

> **Ключевое наблюдение.** Простое удаление всех строк, содержащих пропуски, привело бы к потере более половины набора данных. Для сохранения наблюдений предпочтительно обработать недостающие значения в отдельных признаках.

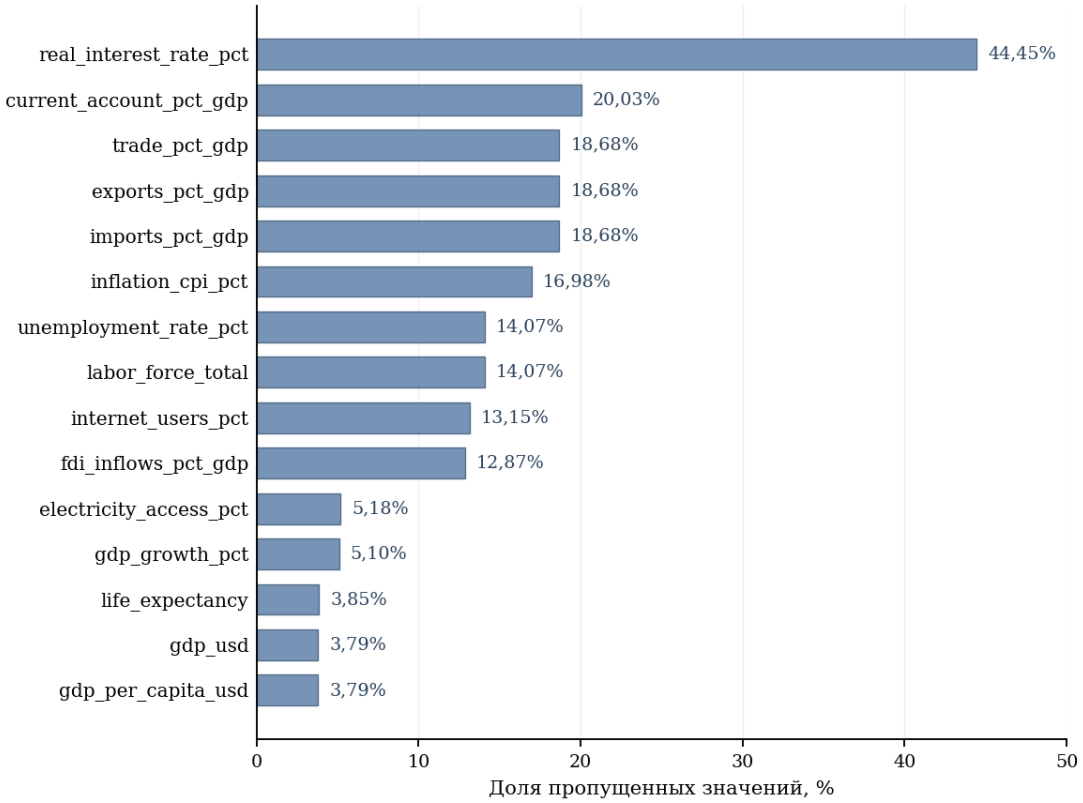


Рисунок 1 - Доля пропущенных значений в исходных столбцах

4.2. Асимметрия распределений

Перед выбором способа заполнения пропусков рассчитаны коэффициенты асимметрии числовых показателей. Значительные положительные значения означают, что распределения имеют выраженный правый хвост и среднее арифметическое может заметно зависеть от экстремальных наблюдений.

```
skewness = data[missing.index].skew(numeric_only=True)
skewness = skewness.sort_values(key=lambda s: s.abs(), ascending=False)
```

Таблица 3 - Наибольшие коэффициенты асимметрии

Признак	Коэффициент асимметрии
inflation_cpi_pct	15,936
fdi_inflows_pct_gdp	11,331
gdp_usd	10,749
labor_force_total	8,881
current_account_pct_gdp	6,790

Таким образом, использование медианы для заполнения пропусков обосновано наличием асимметричных распределений. В отличие от среднего медиана обладает большей устойчивостью к выбросам.

5. Предварительная обработка данных

5.1. Удаление и заполнение пропусков

Столбец real_interest_rate_pct удалён из-за высокой доли отсутствующих значений - 44,45%. В остальных числовых столбцах пропуски заполнены медианами с помощью SimpleImputer(strategy="median"). При этом количество наблюдений сохраняется.

```
work = data.drop(columns=['real_interest_rate_pct']).copy()
num_missing_cols = [
    c for c in work.select_dtypes(include=np.number).columns
    if work[c].isna().any()
]
imputer = SimpleImputer(strategy='median')
work[num_missing_cols] = imputer.fit_transform(work[num_missing_cols])
```

В качестве примера рассмотрен показатель inflation_cpi_pct. Для пропусков в строках с индексами 20-29 записано медианное значение 3,4676 вместо NaN. Размер набора после удаления одного столбца составил (5 642, 18), а общее количество пропусков - 0.

Таблица 4 - Пример заполнения пропусков в inflation_cpi_pct

Индексы строк	До обработки	После обработки
20-24	NaN	3,4676
25-29	NaN	3,4676

Медианная импьютация позволяет использовать все исходные строки, однако подставленные значения являются оценками, а не реальными измерениями; при дальнейшей интерпретации моделей это ограничение следует учитывать.

5.2. Кодирование категориальных признаков

В наборе присутствуют два категориальных столбца: country_code и country_name. Поскольку оба указывают на страну, текстовое название удалено как дублирующее описание. Для идентификатора country_code применено One-Hot Encoding: каждой категории соответствует отдельный бинарный столбец.

```
work = work.drop(columns=['country_name'])
ohe = OneHotEncoder(sparse_output=False, handle_unknown='ignore')
country_encoded = ohe.fit_transform(work[['country_code']])
country_encoded_df = pd.DataFrame(
    country_encoded,
    columns=ohe.get_feature_names_out(['country_code']),
    index=work.index
)
```

Число категорий равно 217, следовательно, сформировано 217 дополнительных бинарных признаков. Например, для Арубы (ABW) столбец country_code_ABW принимает значение 1, остальные индикаторы страны для этой строки равны 0.

Таблица 5 - Пример One-Hot-кодирования стран

Страна	country_code_ABW	country_code_AFG	country_code_AGO
ABW	1	0	0
AFG	0	1	0
AGO	0	0	1

Параметр handle_unknown="ignore" позволяет корректно обрабатывать ранее не встречавшиеся коды при последующем преобразовании: для них не возникает ошибки кодировщика.

5.3. Масштабирование числовых признаков

Значения социально-экономических показателей имеют разные порядки величин: процентные ставки измеряются в процентах, а ВВП - в долларах США. В ноутбуке сопоставлены методы MinMaxScaler и StandardScaler на примере gdp_per_capita_usd.

MinMaxScaler преобразует значения в диапазон от 0 до 1. StandardScaler вычитает среднее арифметическое и делит результат на стандартное отклонение; вследствие этого преобразованные признаки имеют среднее, близкое к нулю, и стандартное отклонение около единицы.

```
scale_example = work[['gdp_per_capita_usd']].copy()
scale_example['MinMaxScaler'] = MinMaxScaler().fit_transform(
    scale_example[['gdp_per_capita_usd']])
scale_example['StandardScaler'] = StandardScaler().fit_transform(
    scale_example[['gdp_per_capita_usd']])
```

Таблица 6 - Сравнение статистик до и после масштабирования

Показатель	mean	std	min	max
Исходный gdp_per_capita_usd	16 012,7307	25 097,6250	109,5938	288 001,5749
MinMaxScaler	0,0552	0,0872	0,0000	1,0000
StandardScaler	0,0000	1,0001	-0,6337	10,8382

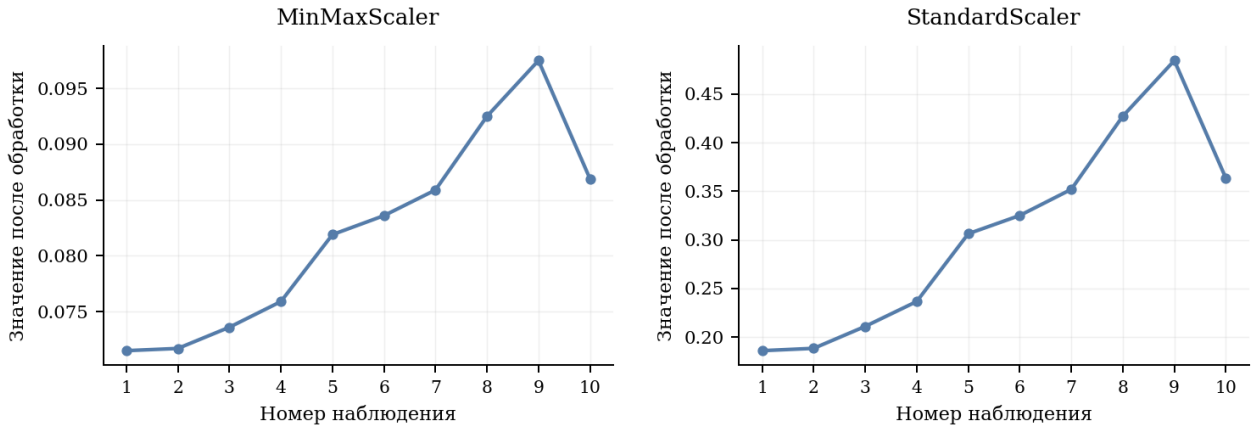


Рисунок 2 - Сравнение масштабирования ВВП на душу населения (первые 10 строк)

Стандартизация не устраняет выбросы: максимальное преобразованное значение для gdp_per_capita_usd равно 10,8382. Для формирования итоговой таблицы выбран StandardScaler, применённый к 15 числовым столбцам. Признак year оставлен без масштабирования.

```
numeric_part = work.drop(columns=['country_code']).copy()
scale_cols = [c for c in numeric_part.select_dtypes(
    include=np.number).columns if c != 'year']
scaler = StandardScaler()
scaled_numeric = numeric_part.copy()
scaled_numeric[scale_cols] = scaler.fit_transform(
    numeric_part[scale_cols])
```

6. Основные результаты

Итоговая матрица получена объединением стандартизованных числовых признаков, года наблюдения и One-Hot-представления стран. Подготовленная таблица записана в файл dataset_preprocessed.csv.

```
processed = pd.concat([
    scaled_numeric.reset_index(drop=True),
    country_encoded_df.reset_index(drop=True)
], axis=1)
processed.to_csv('dataset_preprocessed.csv', index=False)
```

Таблица 7 - Контрольные показатели подготовленного набора

Показатель	Значение
Количество строк	5 642
Количество признаков	233
Количество пропусков	0
One-hot-признаков стран	217
Масштабированных числовых признаков	15
Признак без масштабирования	year

Размерность согласуется с составом итоговой таблицы: 217 бинарных столбцов стран, 15 масштабированных числовых показателей и один столбец year, всего 233 признака. Число строк не изменилось после обработки.

7. Вывод

В ходе лабораторной работы выполнен базовый цикл предварительной обработки данных. Исследованы структура набора и характер пропусков; удалён признак real_interest_rate_pct с долей пропусков 44,45%; остальные отсутствующие числовые значения заполнены медианами. Выполнено One-Hot-кодирование идентификатора страны, а также сравнение нормализации и стандартизации на примере ВВП на душу населения.

После применения StandardScaler к 15 числовым признакам и объединения с категориальными индикаторами получена таблица размером 5 642 × 233 без пропущенных значений. Данные подготовлены для последующего построения моделей машинного обучения. При разработке таких моделей параметры преобразований следует оценивать по обучающей выборке, чтобы избежать утечки информации.